



PyData Granada
MEETUP #16

Patrocina: Cátedra GPU Solutions-UGR
Martes 17 Febrero 18:30h
ETS. Ingenierías Informática y Telecomunicación de la UGR

Ponente
Alberto Prieto Espinosa

Charla:
IA Sostenible: la importancia de la eficiencia energética

Ponente
Josefa Díaz Álvarez

Charla:
Midiendo el consumo energético de tus modelos en Python usando CodeCarbon

Logos: NUMFOCUS, UNIVERSIDAD DE GRANADA, ETSIT, Python España, GPU Solutions

A. Prieto

1

1

IA Sostenible: la importancia de la eficiencia energética

- Alberto Prieto Espinosa, Profesor Emérito



Departamento de
Ingeniería de Computadores, Automática y Robótica



UNIVERSIDAD
DE GRANADA

Patrocina:
Cátedra GPU Solutions-UGR de Infraestructuras de Computación Acelerada e IA Sostenible

Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación
Universidad de Granada
17 de febrero 2026

A. Prieto

2

2

Contenido

- Concepto de Inteligencia Artificial. ¿Qué entendemos por inteligencia?
- Estimaciones sobre la evolución del consumo energético de computación y tráfico de datos digitales
- Algunos datos y situaciones prácticas sobre el consumo de Inteligencia Artificial
- Procedimientos para reducir el consumo energético en TIC
- Conclusiones

A. Prieto

3

3

¿Qué entendemos por Inteligencia Artificial?

A. Prieto

4

4

Qué se entiende por Inteligencia Artificial

- Definición sencilla:
 - La Inteligencia Artificial (IA) es la capacidad de un dispositivo (como un móvil, ordenador o robot) para realizar tareas que generalmente requieren inteligencia humana.
 - Definición mas rigurosa:
 - La Inteligencia Artificial es la disciplina de la Informática que desarrolla sistemas inteligentes, tomando como referencia la inteligencia humana.
 - Ejemplos de IA incluyen los sistemas de reconocimiento de voz y de caras, los coches autónomos, los buscadores en internet o los sistemas que nos recomiendan música o videos.
- Inteligencia (RAE):
 - Capacidad de entender o comprender o de resolver problemas.

• Oliver, N. (2021). Inteligencia artificial, naturalmente: un manual de convivencia entre humanos y máquinas para que la tecnología nos beneficie a todos. Inteligencia artificial, naturalmente, 1-161.

A. Prieto

5

5

Pero, ¿qué entendemos por inteligencia?

- Ejemplos de precedentes:
 - Sistemas automáticos (Templo de Heron)
 - Cálculo. Operaciones matemáticas
 - Cerebros electrónicos, cibernética. ("**Informática**")
 - Jugar al ajedrez
 - Actualidad: en cierta medida Inteligencia Artificial sinónimo de programa informático.


A. Prieto

6

6

¿Qué entendemos por inteligencia?

- Siglo III a de C (autómatas)
 - Puerta templo de Herón de Alejandría
- Edad Media a Siglo XVIII:
 - Autómatas, cabezas parlantes, etc.



A. Prieto

7

7

¿Qué es inteligencia?

- Calcular
 - Hasta sólo hace poco más de un siglo sólo las personas extraordinariamente cultas sabían calcular
- Manuscrito anónimo de época de la reina Elizabeth, 1570:
 - “La multiplicación es una vejación”
 - “La división es un mal”
 - “La regla de tres es un rompecabezas, y utilizarlos me vuelven loco”





A. Prieto

8

8

¿Qué es inteligencia?

- Leonardo Torres Quevedo, en 1912 presentó El Ajedrecista (París, 1914)



A. Prieto

9

9

Diseño del EDVAC

- Von Neumann con el diseño del EDVAC (junio 1945 → 1947) trata de emular el funcionamiento al cerebro dividiéndolo en los siguientes órganos:
 - Input Organ (órgano receptor/sensorial): Unidad de Entrada.
 - Central Control: Unidad Central de Control (CC).
 - Memory Organ: La Memoria ().
 - Central Arithmetic Organ. Unidad Central Aritmética (CA).
 - Output Organ (Órgano Motor/Efector): La Unidad de Salida.
 - Outside recording médium (entre CA y CC) (R)

First Draft of a Report on the EDVAC

by

John von Neumann

Contract No. W-670-ORD-4926

Between the
United States Army Ordnance Department
and the
University of Pennsylvania

• https://archive.computerhistory.org/resources/text/Knuth_Don_X4100/PDF_index/k-8-pdf/k-8-u2593-Draft-EDVAC.pdf

A. Prieto

10

10

2.6 The three specific parts CA, CC together C and M correspond to the associative neurons in the human nervous system. It remains to discuss the equivalents of the sensory or afferent and the motor or efferent neurons. These are the input and the output organs of the device, and we shall now consider them briefly,

A. Prieto


11

11

¿Qué es inteligencia?

- En las décadas de los 1950 y 1960 a los ordenadores o computadores les llamábamos "**Cerebros Electrónicos**", y a la Informática, "**Cibernética**".

- Libro de 1969



A. Prieto

12

12

¿Qué es inteligencia?

- Se decía hasta la década de los 1980. **“Un computador nunca superara a la inteligencia humana, y prueba de ello es que nunca será capaz de ganar al ajedrez a un humano experto”**
- Juego del ajedrez
 - 1997 Deep blue. Primer ordenador capaz de derrotar a un campeón del mundo vigente en ajedrez, Kaspárov. (El computador gano a 6 partidas por 3½ a 2½).
- En diciembre de 2017, AlphaZero, de DeepMind, venció al mejor jugador de ajedrez del mundo (programa Stockfish).
 - **Le bastó conocer las reglas del ajedrez y dedicar cuatro horas a entrenarse, jugando contra sí mismo millones de veces.**



A. Prieto

13

13

AlphaGo gana al campeón del mundo en el juego Go (2016)

- **Go:** Juego Chino que requiere no sólo cálculo sino también intuición y estrategia.
- En cada jugada hay 10^{170} posiciones posible
- **AlphaGo** programa desarrollado por **DeepMind** (filial de Google)
- **Este programa gano 4 a 1 a Lee Sedol (2016)** (poseedor de 18 títulos mundiales) en Seúl. La IA ganó **4 a 1**.



- House, P. (2016). Alphago, Lee Sedol, and the Reassuring Future of Humans and Machines. *The New Yorker*. <https://goo.su/rnm5>
- Rubio, A. Consumo Energético en Sistemas Digitales Avanzados (2025), Conferencia de la IEEE Sección España

A. Prieto

14

14

¿Qué es inteligencia?

- En la actualidad es tan amplio y mediático el término de **Inteligencia Artificial** que vulgarmente (y sin rigor) se esta llegando a utilizar este término como sinónimo de **programa informático**.
 - Dispositivos o sistema inteligente: cualquier dispositivo con sensores, actuadores de salida y posibilidad de comunicación a través de redes (Bluetooth, WiFi, celulares, etc.) con otros dispositivos. En ellos se programan "tomas de decisiones"
 - Internet de las Cosas, teléfonos y relojes "inteligentes", etc.



A. Prieto

15

15

Falta de rigor

IDEAL

Miércoles, 9 de octubre 2019, 14:57

Llegan los parquímetros 'inteligentes' a la zona azul de Granada

Los nuevos parquímetros, dotados con un panel solar orientable, «son máquinas de última generación que permiten algo básico, pero que en Granada no lo había hasta ahora, como es el pago con tarjeta por el tiempo de uso que realmente hacemos de la zona azul. Así, a través de un monedero virtual el usuario puede recuperar el importe del tiempo no consumido».



A. Prieto

16

16

Dos enfoques de la genuina Inteligencia Artificial

- **De arriba abajo (Top-down)**
 - Parte de la descripción precisa (algoritmizada) del proceso inteligente humano en forma de reglas simbólicas que se pueden programar y emular en un computador.
 - Ejemplo: sistema experto
- **De abajo a arriba (conexionista) (Down-top)**
 - Aprendizaje de modelos. El computador genera abstracciones a partir de estímulos sensoriales y otros datos.
 - **Aprendizaje** en máquinas, redes neuronales artificiales, etc.
- **Nota.** El concepto de “toma de decisiones” en computadores lo introdujo Lady Ada Lovelace en 1843. En todos los lenguajes se puede programar la sentencia o estructura lógica “If... then...else...”

A. Prieto

17

17

Problemas de la IA

A. Prieto

18

18

La IA es una herramienta poderosa que genera muchos beneficios, pero también presenta inconvenientes importantes como los siguientes:

- Desplazamiento laboral. En tareas rutinarias o repetitivas, creatividad, etc.
- Sesgos y discriminación. Reproducen los que contenga la información de entrenamiento.
- Opacidad. En ciertos casos se desconocen los argumentos de las tomas de decisiones.
- Uso malintencionado:
 - Filtración de datos confidenciales o personales
 - Noticias falsas (manipulación)
 - Suplantación de personas.
 - Automatización de ciberataques
- Concentración del poder en grandes empresas o países. Aumento de la brecha tecnológica.
- Impacto ambiental. **Alto consumo energético**. Incremento de la temperatura del agua.

• Prieto, A., and Prieto, B. "Five questions and answers about artificial intelligence." arXiv preprint arXiv:2409.15903 (2024). DOI: [10.48550/arXiv.2409.15903](https://doi.org/10.48550/arXiv.2409.15903)

A. Prieto

19

19

Como en la IA y en todas las nuevas tecnologías, la introducción de la iluminación eléctrica creó grandes controversias



Portada de la revista Judge de 26/10/1889 que hace referencia a la muerte del linero John Feeks en Nueva York

• https://www.reddit.com/r/PropagandaPosters/comments/g7a5iw/antielectricity_us_1900s/?tl=es

A. Prieto

20

20

Cartel con instrucciones de uso de la luz eléctrica



'No intente encender la luz con una cerilla. Simplemente gire la llave en la pared junto a la puerta'.

• Frank Schulenburg - Own work, CC BY-SA 4.0, Wikimedia Commons

A. Prieto

21

21

El problema del consumo energético

A. Prieto

22

22

Computación verde (Green Computing) o sostenibilidad en las TIC


- Es el estudio y la práctica de **diseñar, fabricar, usar y eliminar** computadores, servidores y su hardware asociado para consumir energía de manera eficiente y efectiva con un impacto mínimo o nulo en la salud y el medio ambiente.
- Nos vamos a centrar en el “uso”.

- Dhaini, M., Jaber, M., Fakhereldine, A., Hamdan, S., & Haraty, R. A. (2021). Green computing approaches-A survey. Informatica, 45(1)
- IBM (2022) Learn how green computing reduces energy consumption.
[https://www.ibm.com/cloud/blog/green-computing#:~:text=Green%20computing%20\(also%20known%20as,consumed%20by%20manufacturers%2C%20data%20ce](https://www.ibm.com/cloud/blog/green-computing#:~:text=Green%20computing%20(also%20known%20as,consumed%20by%20manufacturers%2C%20data%20ce)

A. Prieto

23

Volumen de computaciones (Hilbert 2011)



- En el año 2040 se estima llegar a una potencia de procesamiento de $\approx 5 \times 10^{22}$ MIPS, una gran parte de los cuales ($\approx 5 \times 10^{19}$ MIPS) corresponderán a procesamiento de uso general.

- M. Hilbert y P. Lopez, "The world's technological capacity to store, communicate, and compute information," Science 332 (2011) 60-65


A. Prieto

24

24

24

Nº de transiciones (procesamientos) necesarias para ejecutar una instrucción (bits/s)



- Con datos reales obtenidos hasta 2015, de 39 procesadores de uso general, se ha estimado, con un alto grado de precisión (coeficiente de determinación $R^2=0,98$) los resultados de la figura.

- F. Roccaforte, F. Giannazzo y G. Greco. (2022, Enero). Ion Implantation Doping in Silicon Carbide and Gallium Nitride Electronic Devices. Micro 2(1) pp. 23-53).
- Semiconductor Industry Association and the Semiconductor Research Corporation, Rebooting the IT Revolution: A Call 547 to Action. (2015)

A. Prieto


25

25

25

V. Zhirnov et al. publican (2014) un artículo donde:

Con datos reales obtienen la evolución del consumo por bit de diferentes elementos binarios (dispositivos lógicos y elementos de memoria)



- V. Zhirnov, R. Cavin y L. Gammaioni. (2014). Minimum energy of computing, fundamental considerations. In ICT-Energy-Concepts Towards Zero-Power Information and Communication Technology. IntechOpen
- Semiconductor Industry Association and the Semiconductor Research Corporation, Rebooting the IT Revolution: A Call 547 to Action. (2015). Append A4

A. Prieto

26

26

V. Zhirnov et al.(2014) llegan a la conclusión de que, en situaciones típicas:

- La energía mínima requerida por transición (conmutación) de un bit es de alrededor de $\approx 10^{-14}$ J/bit.
- Valor estimado como un objetivo alcanzable $\approx 10^{-17}$ J/bit.


- V. Zhirnov, R. Cavin y L. Gammaioni. (2014). Minimum energy of computing, fundamental considerations. In ICT-Energy-Concepts Towards Zero-Power Information and Communication Technology. IntechOpen
- Semiconductor Industry Association and the Semiconductor Research Corporation, Rebooting the IT Revolution: A Call 547 to Action. (2015). Append A4.

A. Prieto

27

27

Proyecciones de Andrae and Edler sobre el uso de energía eléctrica por las TIC en TW·h por año (2015 y 2019)



$$E = P \cdot t$$

$$1 \text{ W} \cdot \text{h} = 3,600 \text{ Joules}$$

$$\text{Tera: } 10^{12}$$

- A.S. Andrae y T. Edler. (2015). On global electricity usage of communication technology: trends to 2030. Challenges, 6(1), 117-157. <https://doi.org/10.3390/challe6010117>
- A.S. Andrae (2019). Comparison of several simplistic high-level approaches for estimating the global energy and electricity use of ICT networks and data centers. International Journal, 5, 51. DOI: 10.30634/2414-2077.2019.05.06


A. Prieto

28

28

Energía eléctrica global consumida por la informática en un año

- Valor calculado a partir de datos reales (2014): $\approx 10^{-14}$ J/bit
- Valor estimado por Zhirnov, como un objetivo a lograr $\approx 10^{-17}$ J/bit
- Límite de Landauer $\approx 3 \cdot 10^{-21}$ J/bit




- Semiconductor Industry Association and the Semiconductor Research Corporation, Rebooting the IT Revolution: A Call 547 to Action. (2015)

A. Prieto

29

29

Evolución mundial de la generación de energía eléctrica anual (PWh)



Peta: 10E15


- Chrifi-Alaoui, L., Drid, S., Ouriagli, M., & Mehdi, D. (2023). Overview of photovoltaic and wind electrical power hybrid systems. *Energies*, 16(12), 4778.

A. Prieto

30

30

En el peor de los casos, en 2042 no habrá energía eléctrica suficiente ...




A. Prieto

31

31

Con nuestros resultados (2025) el límite de Landauer se alcanzaría en 2090




• Prieto, A., Prieto, B., Escobar, J. J., & Lampert, T. (2025). Evolution of computing energy efficiency: Koomey's law revisited. *Cluster Computing*, 28(1), 42.

A. Prieto

32

Hemos obtenido también la evolución el rendimiento de computación (últimos 15 años)

- El rendimiento computacional: dobla cada 1,85 años
- PROBLEMA:
 - La eficiencia energética crece más lentamente (2.29 años)
 - Aunque las diferencias parecen pequeñas, doblar la eficiencia energética cada **1.85 años** significa incrementarla aproximadamente **43 veces en una década** mientras que doblar cada **2.29 años** supone incrementar por **21 por década**.



FLOP: operaciones con nº reales.

FLOPS: operaciones con nº reales por segundo


33

A. Prieto

33

Estimación del consumo de energía en el tráfico por Internet

- Estimaciones de Aslan y cols.:
 - El consumo por bit se reduce a la mitad aproximadamente cada 2 años (en procesamiento cada 2,6 años).
- La energía media de transmisión de 1 bit en 2020 a través de Internet ha sido del orden de **$2,77 \cdot 10^{-6}$ J/bit**, lo que supone:
 - $\approx 2,8 \cdot 10^{11}$ veces mayor que la del procesamiento de un bit (10^{-17} J/b, Zhirnov)
 - 6 ordenes de magnitud mayor según la eficiencia energética de los supercomputadores obtenida por nosotros ($5,5 \cdot 10^{-12}$ J/bit)



- J. Aslan, K. Mayers, J. G. Koomey y C. France. (2018). Electricity intensity of internet data transmission: Untangling the estimates. Journal of industrial ecology, 22(4), 785-798.

A. Prieto

34

34

Aplicaciones genuinas de IA

A. Prieto

35

35

Algunos dominios donde se utiliza aprendizaje profundo

(En los que se puede conocer fácilmente si la respuesta es correcta o no)

- Clasificación de imágenes, ImageNet
- Detección de objetos, MS COCO
- Question answering (SQuAD 1.1) (comprensión lectora sobre artículos Wikipedia)
- Named Entity Recognition CoNLL 2003 (nombres de personas, entidades, lugares, nº de telefonos, países, ciudades, etc.)
- Reconocimiento del habla (ASR SWB Hub500),
- Detección de caras (WIDER Face Hard),
- Generación de imágenes (CIFAR10), and
- Estimación de postura humana (MPII Human Pose).

Thompson, N. C., Greenewald, K., Lee, K., & Manso, G. F. (2020). The computational limits of deep learning. arXiv preprint arXiv:2007.05558.

A. Prieto

36

36

Consumo computacional y energético de aprendizaje profundo en algunas aplicaciones de referencia (proyección exponencial).

Aplicación de referencia	Tasa de error		Nº de operaciones (nº reales, flops)	Emisiones CO ₂ (Tm)	Consumo anual de nº de hogares en España	Costo (€)
Clasificación de imágenes, ImageNet	2022	9.00%	1,00E+25	4,54E+03	363	9,30E+07
	Objetivo 1	5%	1,00E+31	4,54E+10	3.632.000.000	9,30E+14
	Objetivo 2	1%	1,00E+93	4,54E+71	3,63E+70	9,30E+75
Detección de objetos, MS COCO	2022	38.7%	1,00E+23	4,54E+01	4	9,30E+05
	Objetivo 1	30%	1,00E+25	4,54E+04	3.632	9,30E+08
	Objetivo 2	10%	1,00E+50	4,54E+28	3,63E+27	9,30E+32
Comprensión lectora (SQuAD 1.1)	2022	9.4%	1,00E+23	4,54E+02	36	9,30E+05
	Objetivo 1	2%	1,00E+52	4,54E+31	3,63E+30	9,30E+34
	Objetivo 2	1%	1,00E+89	4,54E+67	3,63E+66	9,30E+71
Reconocimiento de nombres de entidades (CoNLL 2003)	2022	5.4%	1,00E+25	4,54E+03	363	9,30E+07
	Objetivo 1	2%	1,00E+62	4,54E+40	3,63E+39	9,30E+44
	Objetivo 2	1%	1,00E+121	4,54E+99	3,63E+98	9,30E+103

Emisiones de un hogar español en 1 año (incluye transporte...): 12,5 Tm CO₂

A. Prieto

37

37



Aprendizaje en Chat GPT-3 175B

- Contenido:
 - **175 mil millones de parámetros** (pesos y otros valores de las redes neuronales).
 - 800 GB de memoria
 - Procesamiento de consultas de hasta 2.048 tokens (palabras o subpalabras), se consideran como “ventana contextual”. Eso significa que tiene 2.048 pistas a lo largo de las cuales se procesan los tokens sucesivos.
- Aprendizaje
 - Actualización enero de 2022.
 - **Pre-entrenamiento no supervisado de red neural profunda (96 capas) con un corpus de 570 mil millones de tokens recopilados de Internet en sitios como Wikipedia (3 mil millones), Common Crawl (410 mil millones), ...**
- Generación de texto
 - 96 capas de ANN transformers decoders (palabra + posición en la frase, etc.) que generan textos que simulan la redacción humana (concepto de “atención”, semántica de las palabras, contexto, etc.)

A. Prieto

38

38

Pre-entrenamiento de GPT-3 175B

- Tiempo total de computación para el pre-entrenamiento:
 - ≈ 3.000 PFLOPS·días




Figure 2.2: Total compute used during training. Based on the analysis in Scaling Laws For Neural Language Models [KMH⁺20] we train much larger models on many fewer tokens than is typical. As a consequence, although GPT-3 3B is almost 10x larger than RoBERTa-Large (355M params), both models took roughly 50 petaflop/s-days of compute during pre-training. Methodology for these calculations can be found in Appendix D.

- Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J. D., Dhariwal, P., ... & Amodei, D. (2020). Language models are few-shot learners. Advances in neural information processing systems, 33, 1877-1901. Cited by 12,240

A. Prieto

39

39

Supongamos que el entrenamiento lo efectuamos con los #1 del TOP500 y Green500 (Noviembre 2025) <https://www.top500.org/>

Rank	TOP500 Rank	System	Cores	Rmax (PFlop/s)	Power (kW)	Energy Efficiency (GFlops/watts)
1	420	KAIROS - BullSequana XH3000, GH Superchip 72C 3GHz, NVIDIA GH200 Superchip, Quad-Rail NVIDIA InfiniBand NDR200, RedHat Enterprise Linux, EVIDEN CALMIP / University of Toulouse - CNRS France	13,056	3.05	46	73.282
23	1	El Capitan - HPE Cray EX255a, AMD 4th Gen EPYC 24C 1.8GHz, AMD Instinct MI300A, Slingshot-11, TOSS, HPE DOE/NNSA/LLNL United States	11,340,000	1,809.00	29,685	60.941

- <https://www.top500.org/>


A. Prieto

40

40

El preentrenamiento a gran escala requiere grandes cantidades de cálculo, lo que consume mucha energía (ChatGPT-3 175B) DATOS 2025

	1º TOP500 (Novi. 2025) El Capitan (USA)	1º Green500 (Novi. 2025) Kairos (Francia)
GPT-3 entrenamiento. PetaFLOPS-días	3.000,00	3.000,00
Gigafllops-día	3,00E+09	3,00E+09
Eficiencia energética (GFlops/watts)	60,94	73,28
W-día	4,92E+07	4,09E+07
KW-h	1,18E+06	9,83E+05
MIX (Kg CO2/KWh) (2026)	0,343	0,044
Huella de carbono (Kg CO2)	405.251,07	43.230,54
Huella equivalente a hogares españoles (nº):	717	77
Prestaciones, Rmax (PFlops)	1.809,00	3,046
Tiempo ejecución (s)	1,43E+05	8,51E+07
Tiempo de ejecución (dd:hh:mm:ss)	01:15:48:04	10:21:33:27
Power (KW)	29.684,62	46,18
Nº de instrucciones (GFLOP) entrenamiento	2,59E+14	2,59E+14
Nº instrucciones (FLOP)	2,59E+23	2,59E+23




405 toneladas de CO2 (1 dd 15 hh) vs 44 ton (10 dd 21 hh)
¡717 / 77 hogares españoles durante 1 año!

A. Prieto

41

41



Emisiones de CO₂ equivalente

Endesa Energía S.A.U.

Emisiones CO₂ eq. (g/kWh)

188

Media nacional (g/kWh)

162

Fenie Energía (2024)

Emisiones CO₂ eq. 270 g/kWh

A. Prieto

42

42

IA sostenible: la importancia de la eficiencia energética. A. Prieto.

	Factor de Emisión (kgCO2/kWh)	Fuente Principal
Paraguay	<0,001	100% Hidroeléctrica. Itaipú (cerca de Yguazú) , Yacaretá
Islandia	0,001	Geotermia e Hidroeléctrica
Noruega	0,007–0,010	Hidroeléctrica >90%
Suecia	0,010–0,015	Nuclear e Hidroeléctrica
Francia	0,030–0,055	≈70% Nuclear
.....		
España	0,113–0,125	Solar, Eólica y Nuclear
.....		
China	0,530–0,550	Mix Térmico (en descenso rápido)
Polonia	0,650–0,690	Carbón (Lignito)
India	0,710–0,725	Carbón y crecimiento de demanda
Sudáfrica	0,880–0,910	Carbón (Lignito) >80%


• Gemini

A. Prieto


43

43


Consumo energético en inferencias SLMs realizadas en PCs.



Text generation (valores medios en Julios)



Text language translation



Code generation inference

Una inferencia: 1,71 Wh

• García-Fernández, P.; Prieto, B.; García-Sánchez, P., Prieto A. Energy Consumption in Personal Computers in the Inference of Large Language Models (*Remitido*)

A. Prieto

44

44

Consumo de inferencias frente a consumo de aprendizaje

- Chat GPT: nº de inferencias por día (2025):
 - 2.500 millones.
- Consumo estimado por inferencia:
 - 3 W·h
- Consumo diario:
 - 7.500 millones de W
- Aprendizaje del Chat GPT 3.5:
 - $1,18 \cdot E6 \text{ KWh} \equiv 393 \cdot E6 \text{ inferencias} \rightarrow 3\text{h}: 46\text{m}$

¡En unas 4 horas de tiempo
se iguala el consumo del
aprendizaje!

- Blake, A. (2025, July 22). Google should be worried – ChatGPT users now send 2.5 billion prompts a day, here's how that compares. Techradar.
- Hutt, G., Viswanathan, V., & Nadolski, A. (2019). Deliver high performance ML inference with AWS Inferentia.
- Wu, C. J., Raghavendra, R., Gupta, U., Acun, B., Ardalani, N., Maeng, K., ... & Hazelwood, K. (2022). Sustainable ai: Environmental implications, challenges and opportunities. *Proceedings of machine learning and systems*, 4, 795-813.

A. Prieto

45

45

Cómo aliviar el problema.

PROCEDIMIENTOS Y TÉCNICAS PARA INCREMENTAR LA EFICIENCIA
ENERGÉTICA EN LAS TIC

A. Prieto

46

46

- Afortunadamente las previsiones más pesimistas (mediados de la década de los 2010) sobre el consumo energético asociado a las TIC no se están cumpliendo, siendo menor que el esperado.
- La industria alrededor de las TIC es consciente del problema y se están invirtiendo recursos financieros y políticas activas para reducir el incremento del consumo, tanto en la fabricación de nuevos productos como en el consumo inherente a su uso.
- Acciones para reducir el consumo:
 - A. Mejoras tecnológicas en los componentes electrónicos y dispositivos**
 - B. Gestión y planificación del uso de los recursos.**
 - C. Cambios de escala**

A. Prieto

47

47

Mejoras tecnológicas en los componentes electrónicos y dispositivos ...

- Estrategias principales utilizadas en el diseño de circuitos “Low Power Design”:
 - **Entrada de reloj:** La señal de reloj no actúa simultáneamente en todos los Flip-Flops; de forma que los no usados no consuman energía.
 - **Ajuste de la lógica:** El diseño lógico de los circuitos se hace considerando su consumo energético como un parámetro de diseño.
 - **Celdas con múltiples tensiones umbrales:** Cuanto menor es la tensión umbral son menores las corrientes de fugas, aunque disminuye la velocidad
 - **Control de la polarización del sustrato:** Se ajusta la tensión de los sustratos, permitiendo así controlar las variaciones y el consumo.
 - **Ajuste de VDD:** Se utilizan diferentes voltajes de alimentación (VDD) que pueden cambiar según la necesidad de rendimiento.
 - **Desconexión de potencia:** Se desconectan secciones enteras del chip cuando no se usan.

• Rubio, A. Consumo Energético en Sistemas Digitales Avanzados (4 dic. 2025), Conferencia de la IEEE Sección España. <https://youtu.be/JLeAH0zVQUU?si=rJFSQAql0xHf6qYl>.



A. Prieto

48

48

...Mejoras tecnológicas en los componentes electrónicos y dispositivos...

- Cambios en los dispositivos y en la arquitectura interior de los microchips.
 - Prototipo de IBM de CI que hace posible apilar verticalmente los transistores-
 - Incremento de la densidad de integración y reducción del consumo de energía (se estima que **hasta un 85% menos**).



IBM's VTFET with a vertical channel (yellow) and gate-all-around (blue). Contacts are brown and the white line shows current flow.

- Zhang, J., Gao, F., & Hu, P. (2021). A vertical transistor with a sub-1-nm channel. *Nature Electronics*, 4(5), 325-325.
- Steve Bush, (14 diciembre 2021) IBM beats finFETs with vertical CMOS at IEDM. *Electronics Weekly.com*

A. Prieto

49

49

... Mejoras tecnológicas en los componentes electrónicos y dispositivos ...

- Inclusión de funciones de gestión de energía dentro de las CPUs con los que, dependiendo de la carga de trabajo, cambian dinámicamente entre diferentes estados de energía (modo de espera, por ejemplo).
- Desarrollo de procesadores de uso específico para ámbitos o funciones concretas, como GPU y TPU.
- Fuentes de alimentación AC/DC conmutadas; introducción de nuevos materiales, como el nitruro de galio y el carburo de silicio, que permiten diseños a más altas frecuencias.




A. Prieto

50

50

... mejoras tecnológicas en los componentes electrónicos y dispositivos ...

- Integración directa en los chips de sistemas de refrigeración con microfluidos, que sustituyan a los ventiladores externos.



Varnava, C. Chips cool off with integrated microfluidics. Nat Electron 3, 583 (2020). <https://doi.org/10.1038/s41928-020-00494-5>


A. Prieto

51

51

Fotónica de silicio

- Fotónica de Silicio: La comunicación óptica dentro de los chips (on-chip) y entre unidades (chip-to-chip) utiliza la **fotónica de silicio** para sustituir por pulsos de luz las señales eléctricas tradicionales, lo que reduce drásticamente el consumo de energía y aumenta el ancho de banda.



• <https://www.fibermall.com/es/blog/overview-of-cpo.htm>

A. Prieto

52

52

Comunicaciones por radiofrecuencia

- Para interconexión de los distintos sistemas de un Centro de Datos, se suelen utilizar cables de cobre o fibras ópticas
- Point2 y AttoTude proponen modulando la información binaria a interconectar en portadoras de radiofrecuencia.
- Estos sistemas de conexión (eTubes) ofrecen mayor alcance, menor consumo de energía y cables más estrechos que los de cobre, sin el costo y la complejidad de la óptica



El rack de Nvidia's GB200 NVL72 utiliza numerosos cables de cobre para conectar sus 72 procesadores. NVIDIA

- Moore, S.K. AI Data Centers Demand More Than Copper Can Deliver, (2026) IEEE Spectrum, January 2026


A. Prieto

53


53

... mejoras tecnológicas en componentes y dispositivos electrónicos

- Cambios en la tecnología de otros dispositivos. HDD → SSD, reducción del consumo de energía superior al 50%
- Computación neuromórfica
 - El cerebro humano es uno de los sistemas más eficientes energéticamente ya que consume una potencia de unos 25 vatios (menos de la mitad de un PC portátil) y dispone de 86.000 millones de elementos informáticos (neuronas).
 - Opino que el bajísimo consumo energético se debe más que a la arquitectura a la tecnología subyacente (material) → en lugar de silicio, arseniuro de galio, etc. el del cerebro es de naturaleza biológica (bioquímica, células, tejidos,...)



pixabay



Wikimedia Commons

A. Prieto

54

54

B. Gestión y planificación del uso de los recursos:

- Utilizar los distintos sistemas tratando de reducir el consumo energético global, como:
 - Hacer entrar en los **modos de suspensión o de espera** a los recursos (servidores, sistemas de memoria etc.) que en un momento dado no sean necesarios.
 - **Escalado dinámico de la tensión y de la frecuencia** (*Dynamic Voltage and Frequency Scaling, DVFS*).
 - Ejecutar lentamente los programas que no necesiten un tiempo de respuesta muy corto.
 - Se estima que, **si la frecuencia de reloj se reduce a la mitad**, el tiempo de ejecución se duplica, pero **el consumo energético se reduce a una cuarta parte**.
 - Ejecutar, en lo posible, las aplicaciones dentro de **“horas valle”** donde la producción de energía eléctrica procedente de fuentes limpias es mayor por ser más elevada la producción eólica debido al viento u horas donde la radiación solar es mayor. Doble beneficio:
 - se reduce el coste económico de la energía necesaria para la ejecución de los programas
 - se favorece el uso de las energías alternativas.

A. Prieto

55

55

C. Cambios de escala

- La proliferación de teléfonos inteligentes y **pequeños dispositivos móviles** da lugar a una reducción del consumo energético ya que cada uno de ellos ofrece multitud de funciones y servicios que antes realizaban dispositivos de consumo independientes.
- Planificación y asignación de tareas a los recursos hardware disponibles teniendo en cuenta su **eficiencia energética**. En particular, debe explotarse el paralelismo de las aplicaciones y de los programas buscando la mejor eficiencia posible.
- **Endoso computacional** (*offloading*): los procesos que requieren tareas informáticas intensivas se transfieren (endosan) a una plataforma externa, que puede ser desde un acelerador de hardware hasta un sistema de clúster, o recursos en la nube. **Tecnologías de virtualización**.
 - Sólo es beneficioso cuando se requiere gran volumen de computación con relativamente poca cantidad de comunicación.
- Fusión o transformación de centros de datos medianos a en **centros de datos hiperescala** (mucho mayores) (Google Cloud, Amazon Web Services, Microsoft Azure, OVHcloud, o Rackspace Open Cloud), donde el consumo de energía se gestiona mucho mejor.

A. Prieto

56

56

Planta de enfriamiento de Google en Hamina (Finlandia)

- Climatización muy crítica y su funcionamiento requiere un gran consumo energético.
- Al ser un país nórdico el coste de la climatización es mucho más bajo que en países más cálidos.
- Este centro utiliza el agua del gélido mar del golfo de Finlandia para refrigerar todas sus instalaciones.




A. Prieto

57

57

Proyecto Natick de Microsoft

- Se sumergieron durante 2 años (2018 a 2020) 864 servidores en un contenedor similar a un submarino.
- Ubicación en las Islas Orcadas, en el norte de Escocia: aguas gélidas y la red eléctrica se abastece al 100% de energía eólica, solar y marina, etc. obtenida en las cercanías. No contaba con refrigeración activa.



• <https://news.microsoft.com/es-es/2020/09/15/proyecto-natick-el-futuro-de-los-centros-de-datos-bajo-el-mar-es-fiabile-practico-y-sostenible/>

A. Prieto

58

58

Proyecto Natick de Microsoft

- Los servidores experimentaron una **tasa de fallos ocho veces inferior** a lo esperado en un Centro de Datos convencional, gracias, entre otras cosas, a la atmósfera de nitrógeno empleada en la cápsula sellada.
- Se rescató del fondo marino, cubierto de algas, percebes y anémonas.
- Se concluyó que **el futuro de los centros de datos bajo el mar es fiable, práctico y sostenible.**



A. Prieto



59

59

Energía Solar Espacial (SBSP)

- La idea principal es capturar la luz del Sol de forma ininterrumpida (sin nubes y sin noches) y enviarla a la superficie mediante señales electromagnéticas.
- Isaac Asimov predijo en 1941 que los satélites podrían transmitir energía a la Tierra. La concepción actual fue propuesta por Peter Glaser en 1968: colocar grandes satélites con paneles solares en órbita geoestacionaria, a unos 36.000 kilómetros sobre la Tierra.
- El Sol es la clave para generar toda la energía que la humanidad requerirá en el futuro, según Elon Musk.
- Ventajas:
 - Energía constante: No depende de la noche (si no son geoestacionarios) ni de las nubes.
 - Alta Intensidad: Fuera de la atmósfera, la luz solar es mucho más potente.
 - Energía Global: Se puede enfocar a distintos puntos remotos del planeta.

A. Prieto


60

60

Esquema de una Base Solar Espacial de energía (SBSP)


- Los módulos para los satélites se producirían en la Tierra y serían ensamblados y mantenidos en el espacio por robots.
- Una vez que los satélites captaran la energía solar, esta se convertiría en ondas electromagnéticas (fotones con $E=h \cdot f$ Julios) y se transmitiría a la Tierra, donde antenas "rectificadoras" las transformarían en electricidad.
- Cada satélite proporcionarían unos dos gigavatios de energía, aproximadamente la misma cantidad que una central nuclear.
- Un panel solar en el espacio puede captar más energía que uno en la Tierra, ya que no tiene que lidiar con días/noches ni con el filtro atmosférico.

A. Prieto



61

61



• <https://www.weforum.org/stories/2022/11/solar-farms-in-space-electricity-to-earth-energy-climate-change/>

A. Prieto

62

62



• <https://www.nagase.com/discover/resources/xenomax-transforming-aerospace-solar-power/xenomax-advancing-thermal-reliability-in-solar-systems>

A. Prieto

63

63



<https://novosti-kosmonavtiki.ru/news/202439/>

A. Prieto

64

64

Conclusiones

A. Prieto

65

65

Conclusiones

- El aumento de la potencia de cálculo (FLOPS) de los computadores ha hecho posible el desarrollo de numerosas aplicaciones de IA; pero la aceleración de los requisitos es permanente mientras que el rendimiento del hardware no aumenta al mismo ritmo.
- Se estima que los modelos de IA duplican la potencia computacional que utilizan cada 3,4 meses (0,28 años) desde 2012; mientras que
 - La potencia de cálculo dobla cada 1,85 años
 - La eficiencia energética crece muchos más lentamente (dobla cada 2.29 años)

A. Prieto

66

66

Conclusiones

- Es de suma importancia forzar al aprendizaje automático hacia técnicas que requieran menos coste computacional y más eficientes desde el punto de vista energético.
 - El desarrollo de algunos modelos está asociado al crecimiento exponencial del nº de parámetros.
- Hay establecidos hitos que hoy día son inalcanzables debido a las extraordinarias necesidades de computo y de energía requeridas.
- Se estima que en el año 2030 las tecnologías de la información consumirán aproximadamente el 13% de la electricidad mundial, y para 2050 el de los centros de datos será unas tres veces mayor que la cantidad total de energía generada en Japón.

A. Prieto

67

67

... conclusiones ...

- El **consumo de energía** debe considerarse como una medida de prestaciones tan importante como el **rendimiento computacional**.
- Por un lado, hay razones medioambientales y económicas, pero también la necesidad de mejorar la autonomía de los dispositivos que utilizan baterías.
- La reducción del consumo energético en el ámbito de las TIC es una cuestión trascendental, y debe ser afrontada desde muy distintos ámbitos (computer engineering, software engineering, dissemination-users, teaching, etc.)
- La sociedad debe estar informada de que el uso de las TIC (sea cual sea su forma), lleva implícito un consumo energético. **¡Todos debemos contribuir, desde nuestros respectivos ámbitos, al reto de lograr la sostenibilidad de nuestro planeta!**


A. Prieto

68

68

A largo plazo:

Lo que nos espera 😊



A. Prieto

69

69

Agradecimientos

- Deseo agradecer a las siguientes personas su colaboración en las investigaciones que estamos realizando sobre estos temas:

- Beatriz Prieto Campos
- Christian Morillas
- Jesús González Peñalver
- Miguel Damas
- Juan José Escobar
- Pablo García Sánchez
- Antonio Díaz
- Francisco Illeras

Nuestras investigaciones en este ámbito actualmente se están financiando por:

Proyectos **PID2022-137461NB-C31**, **PID2023-147409NB-C21** financiados por MICIU/AEI/10.13039/501100011033 and by ERDF, "a way of making Europe", y C-ING-027-UGR23 financiado por la Consejería de Universidades, Investigación e Innovación y la UE, Andalucía ERDF Program.



A. Prieto

70

70

¡Muchas gracias por vuestra atención!

- Alberto Prieto Espinosa.
- Conferencias:
<https://icar.ugr.es/informacion/directorio-personal/alberto-prieto-espinosa/web/conferencias>

A. Prieto

